Contribution title

First Author[1][0000-1111-2222-3333], Second Author[2,3][1111-2222-3333-4444], and Third Author[3][2222–3333-4444-5555]

[1] Princeton University, Princeton NJ 08544, USA
[2] Springer Heidelberg, Tiergartenstr. 17, 69121 Heidelberg, Germany
lncs@springer.com
http://www.springer.com/gp/computer-science/lncs
[3] ABC Institute, Rupert-Karls-University Heidelberg, Heidelberg, Germany
{abc,lncs}@uni-heidelberg.de

Resumen The abstract should briefly summarize the contents of the paper in 150–250 words. This is the English version of the abstract that provides a comprehensive overview of the research conducted, the methodology used, and the main findings obtained.

Keywords: first keyword· second keyword· another keyword

Título de la contribución

Resumen En este artículo se aborda el problema de la explicabilidad en modelos de aprendizaje automático mediante métodos de feature attribution.
En particular, se estudia una variante de los Shapley values conocida como Asymmetric Shapley Values (ASV), que permite incorporar conocimiento causal en la explicación de modelos de forma model-agnostic. A partir del análisis de su complejidad, se demuestra que el cálculo exacto de ASV es polinomial en modelos cuya distribución de entrada está representada por una red bayesiana del tipo Naive Bayes, en contraste con SHAP, que es #P-hard aún en este caso restringido.
Con el objetivo de extender estos resultados a clases más generales de redes bayesianas, se introduce una noción de clases de equivalencia sobre los órdenes topológicos del grafo causal subyacente, lo cual permite reducir drásticamente el número de permutaciones necesarias para computar ASV. Se presenta un algoritmo polinomial en el número de clases para identificarlas, y se implementa un esquema de cómputo exacto de ASV basado en estas clases. Además, se propone un nuevo método para computar en tiempo polinomial la predicción esperada de un árbol de decisión, sobre una distribución dada por una red bayesiana arbitraria, permitiendo así evaluar el algoritmo desarrollado para el cómputo de ASV en estos modelos.

Por último, se propone un algoritmo aproximado para calcular el ASV en familias de DAG's causales del tipo polytree. Para ello, se desarrolla un algoritmo de muestreo aleatorio de órdenes topológicos de polytrees. Estos resultados respaldan la viabilidad del enfoque propuesto en estructuras causales realistas, y se contrastan empíricamente con SHAP tanto en precisión como en eficiencia computacional.

Keywords: explicabilidad, árboles de decisión, Asymmetric Shapley Values (ASV), Shap, polytrees, ordenes topológicos

TODO

- Escribir todo xD

1. Introducción

En los últimos años, las capacidades de los modelos de inteligencia artificial han crecido de forma acelerada, al igual que la complejidad de sus arquitecturas. Este avance permitió resolver tareas que antes parecían inalcanzables, como la resolución de problemas matemáticos complejos por parte de modelos de lenguaje et. al, 2024. Al mismo tiempo, los modelos actuales han alcanzado escalas muy superiores a las de hace algunos años, tanto en cantidad de parámetros como en complejidad estructural Epoch AI, 2024. Esta falta de transparencia es especialmente problemática en contextos sensibles, como diagnósticos médicos o decisiones de alto impacto, donde no alcanza con obtener una predicción correcta: también es fundamental comprender cómo fue alcanzada. En este contexto surge el área de *Explainable Artificial Intelligence* (XAI), cuyo objetivo es desarrollar métodos que permitan explicar las decisiones de los modelos.

Dentro del área de explicabilidad, uno de los enfoques más influyentes es el de *feature attribution*, donde se asigna a cada variable de entrada un puntaje que refleja cuánto contribuyó a una predicción. En esta línea, *SHAP* es uno de los métodos más conocidos Lundberg y Lee, 2017. Está basado en los *Shapley values*, un concepto originado en teoría de juegos cooperativos Shapley et al., 1953. Intuitivamente, los Shapley values permiten repartir de manera justa el valor total obtenido por una coalición entre sus participantes, según cuánto aporta cada uno en promedio al incorporarse. Trasladado al aprendizaje automático, las features juegan el rol de los jugadores, y el valor asignado a cada una busca cuantificar cuánto contribuye a la predicción del modelo para una instancia particular.

A pesar de su popularidad, SHAP presenta limitaciones importantes. Por un lado, su cálculo exacto suele ser costoso, ya que requiere considerar una

cantidad exponencial de subconjuntos o permutaciones de features. De hecho, existen resultados que muestran que calcular SHAP resulta intratable incluso para modelos o distribuciones relativamente simples Arenas et al., 2021, 2023; Marzouk et al., 2025; Van den Broeck et al., 2022. Por otro lado, también existen cuestionamientos sobre la calidad de las explicaciones que produce. En particular, no siempre resulta claro cómo interpretar en inteligencia artificial los axiomas heredados de la teoría de juegos, y varios trabajos señalan que estas explicaciones pueden fallar en reflejar adecuadamente relaciones de dependencia, relevancia o causalidad entre las variables Fryer et al., 2021; Huang y Marques-Silva, 2023; Marques-Silva, 2023. Más en general, tampoco existe un consenso absoluto sobre qué debe considerarse una "explicación" en IA: muchas de las técnicas actuales son aproximaciones pragmáticas a un problema mucho más amplio, relacionado con comprensión, causalidad e interpretación humana Lipton, 2017; Miller, 2019.

Una propuesta para superar algunas de estas limitaciones son los *Asymmetric Shapley Values* (ASV), introducidos por Frye et al. Frye et al., 2019. Esta variante incorpora información causal al cálculo de los puntajes, restringiendo la atención a aquellas permutaciones de variables que respetan un grafo causal. De este modo, en lugar de tratar a todas las features simétricamente, se priorizan aquellas que aparecen causalmente antes que otras. Esto puede producir explicaciones más fieles al proceso generador de los datos y ayudar a detectar mejor fenómenos como sesgos o discriminación. Además, aunque ASV fue propuesto principalmente para mejorar la calidad explicativa, surge naturalmente la pregunta de si esta restricción adicional también puede traer beneficios desde el punto de vista computacional.

En esta tesis estudiamos el problema de calcular ASV cuando la distribución de los datos está representada por una red bayesiana. En particular, analizamos tanto el cómputo exacto como aproximado de ASV, considerando a la red bayesiana también como grafo causal subyacente. Mostramos que, en el caso de distribuciones Naive Bayes, ASV puede calcularse en tiempo polinomial en escenarios donde SHAP resulta intratable Van den Broeck et al., 2022. A partir de este resultado, nos enfocamos en árboles de decisión y en el desarrollo de algoritmos para calcular eficientemente predicciones promedio y explicaciones causales en estructuras más generales.

Echu: Esto se puede cambiar todavía, la verdad no tenemos muy clara cómo va a ser la estructura así que lo dejo cómo placeholder.

El resto del trabajo se organiza de la siguiente manera. En la Sección 2 introducimos las definiciones formales necesarias sobre SHAP, ASV, clasificadores y distribuciones probabilísticas. En la Sección 3 presentamos los principales resultados teóricos y de complejidad, junto con los algoritmos desarrollados. Luego, en la Sección 4 mostramos resultados experimentales que ilustran y validan el enfoque propuesto. Finalmente, en la Sección 5 discutimos las conclusiones y posibles líneas de trabajo futuro.

1.1. Explicaciones basadas en causalidad: un ejemplo con la red Cancer

Para ilustrar cómo la información causal puede afectar las explicaciones de un modelo, consideramos la red bayesiana *Cancer*, mostrada en la Figura 1a. En esta red, las variables `Pollution` y `Smoker` influyen sobre `Cancer`, mientras que `Xray` y `Dyspnoea` son consecuencias de esta última.

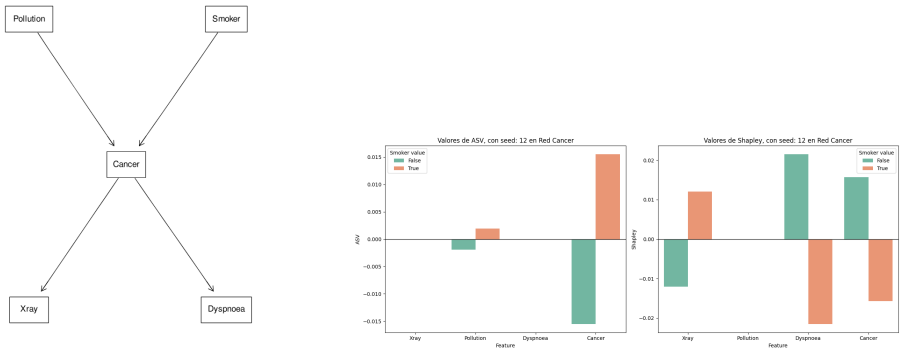

(a) Red bayesiana *Cancer*.

(b) Comparación entre SHAP y ASV.

Figura 1: Ejemplo en la red *Cancer*. SHAP puede asignar relevancia a variables que son consecuencias de otras (como `Xray` o `Dyspnoea`), mientras que ASV prioriza variables causalmente más cercanas al fenómeno.

A partir de datos sampleados de esta red entrenamos un árbol de decisión para predecir la variable `Smoker`. En este contexto podemos comparar dos formas de explicar una predicción: los valores de SHAP, que consideran todas las permutaciones posibles de features, y los Asymmetric Shapley Values (ASV), que restringen el cálculo a órdenes topológicos compatibles con la estructura causal del grafo.

La Figura 1b muestra un ejemplo de esta comparación. Se observa que SHAP asigna relevancia considerable a variables como `Xray` y `Dyspnoea`, que en la red son consecuencias de `Cancer`. Esto ocurre porque dichas variables pueden estar fuertemente correlacionadas con la predicción, aun cuando no sean causas directas del fenómeno. En cambio, ASV tiende a priorizar variables más cercanas a las causas del proceso generador de los datos, reduciendo la importancia de variables descendientes.

Este ejemplo ilustra cómo incorporar información causal puede producir explicaciones más alineadas con la estructura del problema. En redes donde se conoce (o se asume) una relación causal entre las variables, los ASVs permiten distinguir mejor entre variables que originan información relevante para la predicción y variables que simplemente reflejan efectos de otras.

2. Definiciones

En esta sección introducimos las nociones formales que utilizaremos a lo largo del trabajo. Primero definimos los *Shapley values* y su instanciación al problema de *feature attribution*. Luego presentamos los *Asymmetric Shapley Values* (ASV), que incorporan información estructural mediante un grafo causal. Finalmente, introducimos las redes bayesianas como modelo para la distribución de los datos y describimos las familias restringidas de redes que consideraremos en nuestros resultados.

2.1. Shapley values y feature attribution

Trabajaremos con clasificadores binarios y features binarias. Esta restricción simplifica la notación sin afectar las ideas centrales ni los algoritmos desarrollados, que pueden extenderse naturalmente a dominios finitos más generales.

Sea X un conjunto finito de features. Una *entidad* sobre X es una función

$$e : X \to \{0, 1\},$$

donde $e(x)$ representa el valor que la entidad e toma en el feature x. Denotamos por $\texttt{ent}(X)$ al conjunto de todas las entidades posibles sobre X, y asumimos dada una distribución de probabilidad Pr sobre $\texttt{ent}(X)$. Un *clasificador binario* es una función

$$M : \texttt{ent}(X) \to \{0, 1\}.$$

Dado un modelo M y una entidad e, un *feature attribution score* es una función

$$\phi : X \to \mathbb{R},$$

donde $\phi(x)$ mide la relevancia del feature x respecto de la predicción $M(e)$.

Uno de los métodos de atribución más estudiados es SHAP-SCORE Lundberg y Lee, 2017, basado en los *Shapley values* Shapley et al., 1953. En teoría de juegos cooperativos, los Shapley values describen cómo repartir el valor total obtenido por una coalición entre sus jugadores. Más precisamente, dado un conjunto finito de jugadores $\mathcal{I}$, una *función característica* es una función

$$\nu : \mathcal{P}(\mathcal{I}) \to \mathbb{R}$$

que asigna un valor a cada coalición. Los Shapley values son la única asignación de pagos que satisface simultáneamente un conjunto de axiomas clásicos: *eficiencia*, *simetría*, *jugador nulo* y *linealidad*. Una forma cerrada de definirlos es la siguiente.

Definition 1 (Shapley values). *Sea $\mathcal{I}$ un conjunto finito y sea $\nu : \mathcal{P}(\mathcal{I}) \to \mathbb{R}$ una función característica. Para cada jugador $i \in \mathcal{I}$, su valor de Shapley se define como*

$$\phi_i(\nu) = \frac{1}{|\mathcal{I}|!} \sum_{\pi \in perm(\mathcal{I})} \left[\nu(\pi_{<i} \cup \{i\}) - \nu(\pi_{<i}) \right], \tag{1}$$

donde perm($\mathcal{I}$) es el conjunto de todas las permutaciones de $\mathcal{I}$, y $\pi_{<i}$ denota el conjunto de jugadores que aparecen antes que i en la permutación π.

Intuitivamente, esta expresión promedia la contribución marginal de un jugador sobre todos los órdenes posibles de llegada al juego. De manera equivalente, puede escribirse como

$$\phi_i(\nu) = \sum_{S \subseteq \mathcal{I} \setminus \{i\}} c_{|S|} \left[\nu(S \cup \{i\}) - \nu(S) \right],$$

donde

$$c_m = \frac{m!(|\mathcal{I}| - m - 1)!}{|\mathcal{I}|!}.$$

En aprendizaje automático, el conjunto de jugadores se identifica con el conjunto de features X, en nuestro ejemplo de la red *Cancer*, X sería el conjunto `Cancer, Pollution, Dyspnoea, Xray`. Dada una entidad e y un subconjunto $S \subseteq X$, queremos evaluar el comportamiento promedio del modelo al fijar los valores de las variables de S según la entidad e y marginalizar el resto de acuerdo con la distribución de los datos.

Para ello, definimos primero el conjunto de entidades *consistentes* con e en S:

$$\mathtt{cw}(e, S) = \{e' \in \mathtt{ent}(X) : e'(x) = e(x) \text{ para todo } x \in S\}.$$

La probabilidad condicionada a este conjunto queda dada por

$$\Pr[e' \mid \mathtt{cw}(e, S)] = \begin{cases} \dfrac{\Pr[e']}{\sum\limits_{e'' \in \mathtt{cw}(e,S)} \Pr[e'']} & \text{si } e' \in \mathtt{cw}(e, S), \\ 0 & \text{en caso contrario.} \end{cases}$$

Con esta notación, la función característica asociada a M, e y Pr se define como la predicción promedio condicionada a los valores fijados en S.

Definition 2 (Función característica inducida por un modelo). *Dados un modelo M, una entidad e y una distribución* Pr *sobre* $\mathtt{ent}(X)$*, definimos*

$$\nu_{M,e,\Pr}(S) = \sum_{e' \in \mathtt{cw}(e,S)} \Pr[e' \mid \mathtt{cw}(e, S)]\, M(e'). \tag{2}$$

Esto nos permite instanciar directamente los Shapley values en el problema de *feature attribution*.

Definition 3 (SHAP). *Dado un modelo M, una entidad e, una distribución* Pr *y un feature $x_i \in X$, el valor SHAP de x_i se define como*

$$Shap_{M,e,\Pr}(x_i) = \sum_{S \subseteq X \setminus \{x_i\}} c_{|S|} \left[\nu_{M,e,\Pr}(S \cup \{x_i\}) - \nu_{M,e,\Pr}(S) \right].$$

Nótese que los axiomas que estos valores satisfacen no tienen un significado claro en el contexto de la inteligencia artificial, ya que dependen de la definición de $\nu_{M,e,\Pr}$ Fryer et al., 2021. Además, para algunas nociones simples y robustas de *feature attribution* basadas en *explicaciones abductivas* Marques-Silva, 2023, los Shapley values no logran asignar un puntaje de 0 a features irrelevantes Huang y Marques-Silva, 2023. Aun así, constituyen uno de los marcos más influyentes para estudiar explicaciones locales basadas en atribución.

2.2. Asymmetric Shapley Values y grafos causales

La definición anterior trata a todas las permutaciones de features de manera uniforme. Sin embargo, en muchos problemas existe información estructural adicional que sugiere que no todos los órdenes son igualmente razonables. En particular, si se dispone de un grafo causal sobre las variables, resulta natural restringir la atención a aquellas permutaciones compatibles con dicha estructura.

La generalización más simple consiste en reemplazar el promedio uniforme por una función de pesos arbitraria sobre permutaciones.

Definition 4 (Shapley values ponderados). *Sea $w : perm(\mathcal{I}) \to \mathbb{R}$ una función tal que $\sum_{\pi \in perm(\mathcal{I})} w(\pi) = 1$. Definimos*

$$\phi_i^{assym}(\nu) = \sum_{\pi \in perm(\mathcal{I})} w(\pi) \left[\nu(\pi_{<i} \cup \{i\}) - \nu(\pi_{<i})\right]. \tag{3}$$

La familia de *Asymmetric Shapley Values* propuesta en Frye et al., 2019 surge al elegir la función de pesos a partir de un DAG que codifica relaciones causales entre las features.

Definition 5 (Asymmetric Shapley Values). *Sea $G = (X, E)$ un DAG cuyos nodos son los features. Denotemos por $topos(G)$ al conjunto de órdenes topológicos de G. Definimos la función de pesos*

$$w(\pi) = \begin{cases} \frac{1}{|topos(G)|} & \text{si } \pi \in topos(G), \\ 0 & \text{en otro caso.} \end{cases}$$

Entonces, dado un modelo M, una entidad e y una distribución $\Pr$, el valor ASV de un feature $x_i \in X$ se define como

$$Shap^{assym}_{M,e,\Pr}(x_i) = \frac{1}{|topos(G)|} \sum_{\pi \in topos(G)} \left[\nu_{M,e,\Pr}(\pi_{<i} \cup \{x_i\}) - \nu_{M,e,\Pr}(\pi_{<i})\right].$$

La intuición detrás de esta definición es que sólo se consideran órdenes que respetan la causalidad. De este modo, si una variable x es causa de una variable y, entonces x siempre aparece antes que y en las permutaciones admitidas. Esto tiende a favorecer a las variables causalmente anteriores y a reducir la importancia de variables que son meramente consecuencias de otras. En consecuencia, ASV constituye una variante de SHAP diseñada para capturar asimetrías estructurales entre las features.

2.3. Redes bayesianas como modelo de distribución

Para evaluar las cantidades definidas arriba no alcanza con fijar un modelo predictivo: también es necesario especificar una distribución sobre el espacio de entidades. En este trabajo utilizamos redes bayesianas para representar dicha distribución.

Definition 6 (Red bayesiana). *Una Red Bayesiana N sobre un conjunto de variables X es una tupla*

$$N = (X, E, \Pr),$$

donde (X, E) es un DAG y, para cada variable $x \in X$, se especifica una distribución condicional

$$\Pr(x \mid \mathit{Parents}(x)).$$

*Estas distribuciones se representan mediante tablas de probabilidad condicional (*Conditional Probability Tables*, CPTs).*

La propiedad central de una red bayesiana es que factoriza la distribución conjunta usando únicamente dependencias locales. Si $X = \{X_1, \ldots, X_n\}$, entonces

$$\Pr(X_1, \ldots, X_n) = \prod_{i=1}^{n} \Pr(X_i \mid \mathit{Parents}(X_i)).$$

Esta factorización permite realizar inferencia probabilística de forma mucho más eficiente que manipulando directamente la distribución conjunta.

Conviene distinguir con cuidado entre *red causal* y *red bayesiana*. Una red bayesiana modela dependencias condicionales y define una distribución conjunta; un grafo causal, en cambio, pretende reflejar relaciones de causa y efecto entre variables. En general, ambas nociones no coinciden necesariamente. Sin embargo, en este trabajo asumiremos que el DAG subyacente a la red bayesiana puede utilizarse también como grafo causal para definir ASV. Esta decisión responde a dos motivos: por un lado, es consistente con el tipo de datos y experimentos que analizamos; por otro, nos permite estudiar simultáneamente el costo de la inferencia probabilística y el efecto de imponer restricciones causales en el cálculo de explicaciones.

Más precisamente, dado un modelo M, una entidad e y una red bayesiana N sobre las features, utilizaremos la distribución inducida por N para calcular la función característica $\nu_{M,e,\Pr}$, y el DAG de N como estructura causal para definir $\mathit{Shap}^{assym}_{M,e,\Pr}$.

2.4. Familias restringidas de redes bayesianas

La complejidad de la inferencia en redes bayesianas depende fuertemente de la estructura del grafo subyacente. En redes generales, calcular probabilidades marginales o condicionadas es un problema #P-HARD, mientras que para ciertas familias restringidas la inferencia puede realizarse en tiempo polinomial. Por esta razón, nuestros resultados se concentran en clases estructurales bien delimitadas.

La primera familia que consideramos es la de las redes *Naive Bayes*. En este caso, existe una variable raíz X_1 tal que todas las demás variables son sus hijas, y no hay otras aristas. Es decir, el conjunto de aristas es

$$E = \{(X_1, X_j) : 2 \leq j \leq n\}.$$

La distribución conjunta factoriza entonces como

$$\Pr[e] = \Pr[X_1 = e(X_1)] \prod_{j=2}^{n} \Pr[X_j = e(X_j) \mid X_1 = e(X_1)].$$

Echu: Hace falta mostrar la fórmula de la probabilidad o mejor mostrar la imagen de que estructure tiene y listo? Igual la imagen ocupa espacio y no suma tanto, tal vez no hace falta ninguna de las dos.

Esta familia es especialmente relevante porque, aunque su estructura es muy simple, ya permite exhibir una diferencia fundamental entre SHAP y ASV: se sabe que calcular SHAP sobre distribuciones Naive Bayes es intratable incluso para modelos muy simples Van den Broeck et al., 2022, mientras que uno de nuestros resultados muestra que ASV puede ser tratable en este escenario.

La segunda familia central en este trabajo es la de los *polytrees*, es decir, DAGs cuyo grafo subyacente no dirigido es un árbol. Esta clase resulta importante porque admite inferencia probabilística en tiempo polinomial Pearl, 1986. Como el cálculo de la función característica involucra predicciones promedio condicionadas a evidencia, la posibilidad de realizar inferencia eficiente en la distribución de entrada es un ingrediente fundamental para obtener algoritmos tratables para ASV.

Echu: ¿Se dice tratable o tractable?

En síntesis, a lo largo de esta tesis trabajaremos principalmente con dos tipos de restricciones estructurales sobre la distribución de los datos: redes Naive Bayes, que sirven como caso base para nuestros resultados de tractabilidad, y polytrees, que constituyen la clase más general sobre la que desarrollamos algoritmos eficientes para inferencia y cómputo de explicaciones.

3. Theoretical results

1. Resultado de que ASV se puede calcular en algunos casos donde el otro no se podía (el caso se la naiva bayes digo). Creo que no hay apendice, asi que diria de, en principio, poner todas las demos en el main text. Tienen que estar prolijas.
2. Idea de las clases de equivalencia. Definición y relación con la cantidad de órdenes topológicos.
3. Descripción general del algoritmo basado en clases de equivalencias para cómputo exacto.
4. Instanciar este algoritmo en el caso de árboles y dar la complejidad.
5. Introducir la opción de samplear para aproximar el ASV, tanto clases de equivalencia como ordenes topológicos.

6. Dar dos resultados generales diciendo "Si podes samplear clases / ordenes en X tiempo y calcular promedios en Y, la complejidad es f(XY)".
7. Instanciar este resultado en casos particulares. Hablar de los algoritmos para promedios de arboles. Capaz el resultado de imposibilidad.
8. Dar el resultado basado en sampleo de ordenes topologicos en general.

4. Experimental results

1. Comparación entre clases de equivalencia y ordenes topologicos.
2. Algun resultado de performance sobre algoritmos de clases de equivalencias.
3. Si podemos, estaria bueno implementar el otro algoritmo basado en sampleo de ordenes topologicos.
4. No me parece necesario contar la performance de los algoritmos que calculan promedios, aunque si hay lugar podemos.
5. Si hay lugar tambien podriamos hacer una comparacion de shapley y ASV (no me queda claro si hay o no pq son 14 paginas pero el formato es una verga)

5. Conclusions

6. First Section

6.1. A Subsection Sample

Please note that the first paragraph of a section or subsection is not indented. The first paragraph that follows a table, figure, equation etc. does not need an indent, either.

Subsequent paragraphs, however, are indented.

Sample Heading (Third Level) Only two levels of headings should be numbered. Lower level headings remain unnumbered; they are formatted as run-in headings.

Sample Heading (Fourth Level) The contribution should contain no more than four levels of headings. Table 1 gives a summary of all heading levels.
Displayed equations are centered and set on a separate line.

$$x + y = z \tag{4}$$

Please try to avoid rasterized images for line-art diagrams and schemas. Whenever possible, use vector graphics instead (see Fig. **??**).

Theorem 1. *This is a sample theorem. The run-in heading is set in bold, while the following text appears in italics. Definitions, lemmas, propositions, and corollaries are styled the same way.*

Tabla 1: Table captions should be placed above the tables.

Heading level	Example	Font size and style
Title (centered)	**Lecture Notes**	14 point, bold
1st-level heading	**1 Introduction**	12 point, bold
2nd-level heading	**2.1 Printing Area**	10 point, bold
3rd-level heading	**Run-in Heading in Bold.** Text follows	10 point, bold
4th-level heading	*Lowest Level Heading.* Text follows	10 point, italic

Demostración. Proofs, examples, and remarks have the initial word in italics, while the following text appears in normal font.

For citations of references, we use the APA 7 convention. The following bibliography provides a sample reference list with entries for journal articles (**ref_article1**), an LNCS chapter (**ref_lncs1**), a book (**ref_book1**), proceedings without editors (**ref_proc1**), and a homepage (**ref_url1**). Multiple citations are grouped (**ref_article1**; **ref_lncs1**; **ref_book1**), (**ref_article1**; **ref_book1**; **ref_proc1**; **ref_url1**).

Acknowledgments. A bold run-in heading in small font size at the end of the paper is used for general acknowledgments, for example: This study was funded by X (grant number Y).

Disclosure of Interests. It is now necessary to declare any competing interests or to specifically state that the authors have no competing interests. Please place the statement with a bold run-in heading in small font size beneath the (optional) acknowledgments, for example: The authors have no competing interests to declare that are relevant to the content of this article. Or: Author A has received research grants from Company W. Author B has received a speaker honorarium from Company X and owns stock in Company Y. Author C is a member of committee Z.

Referencias

Arenas, M., Barceló, P., Bertossi, L., & Monet, M. (2021). The tractability of Shap-score-based explanations for classification over deterministic and decomposable Boolean circuits. *Proceedings of the AAAI Conference on Artificial intelligence*, *35*, 6670-6678.

Arenas, M., Barceló, P., Bertossi, L., & Monet, M. (2023). On the complexity of Shap-score-based explanations: Tractability via knowledge compilation and non-approximability results. *Journal of Machine Learning Research*, *24* (63), 1-58.

Epoch AI. (2024, junio). Data on Large-Scale Ai Models [Accessed: 2025-04-14]. https://epoch.ai/data/large-scale-ai-models

et. al, E. G. (2024). FrontierMath: A Benchmark for Evaluating Advanced Mathematical Reasoning in Ai. https://arxiv.org/abs/2411.04872

Frye, C., Rowat, C., & Feige, I. (2019). Asymmetric Shapley values: incorporating causal knowledge into model-agnostic explainability. *arXiv preprint arXiv:1910.06358*.

Fryer, D., Strümke, I., & Nguyen, H. (2021). Shapley values for feature selection: The good, the bad, and the axioms. *Ieee Access*, *9*, 144352-144360.

Huang, X., & Marques-Silva, J. (2023). The inadequacy of Shapley values for explainability. *arXiv preprint arXiv:2302.08160*.

Lipton, Z. C. (2017). The Mythos of Model Interpretability. https://arxiv.org/abs/1606.03490

Lundberg, S., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. https://arxiv.org/abs/1705.07874

Marques-Silva, J. (2023). Logic-based explainability in machine learning. En *Reasoning Web. Causality, Explanations and Declarative Knowledge: 18th International Summer School 2022, Berlin, Germany, September 27–30, 2022, Tutorial Lectures* (pp. 24-104). Springer.

Marzouk, R., Bassan, S., Katz, G., & de la Higuera, C. (2025). On the Computational Tractability of the (Many) Shapley Values. https://arxiv.org/abs/2502.12295

Miller, T. (2019). Explanation in Artificial intelligence: Insights from the social sciences. *Artificial Intelligence*, *267*, 1-38. https://doi.org/https://doi.org/10.1016/j.artint.2018.07.007

Pearl, J. (1986). Fusion, Propagation, and Structuring in Belief Networks. *Artificial Intelligence*, *29*(3), 241-288.

Shapley, L. S., et al. (1953). A value for n-person games. *Classics in game theory*.

Van den Broeck, G., Lykov, A., Schleich, M., & Suciu, D. (2022). On the tractability of Shap explanations. *Journal of Artificial Intelligence Research*, *74*, 851-886.